

NIM free Super120 playbook

Smoke int
de produç

1. Fontes oficiais

Quickstart: <https://docs.api.nvidia.com/nim/docs/api-quickstart>

Catalogo: <https://build.nvidia.com/models>

Host API: <https://integrate.api.nvidia.com/v1>

Produto/FAQ: <https://docs.api.nvidia.com/nim/docs/product>

2. ID live (esta conta)

`nvidia/nemotron-3-super-120b-a12b`

Smoke autenticado: HTTP 200, nvcf fulfilled. Preferir este ID. Em 503: retry o MESMO SKU.

Skip: llama-3.3-nemotron-super-49b-v1 / v1.5 = HTTP 410 (nao tratar como EOL oficial). Instruct 70B/51B = 404 nesta conta.

Round5: Super120 200x3; ising-calibration-1.5-31b, nemoguard-content-safety, safety-guard-8b-v3 tambem 200. GET /v1/models: 81 IDs, 32 nvidia/*.

3. Smoke minimo (free-tier)

1) GET /v1/models (Bearer). 2) POST /v1/chat/completions no Super120, max_tokens baixo. 3) Relatorio HTTP + usage + recorte -- sem secrets.

```
curl -sS -H "Authorization: Bearer NVIDIA_API_KEY" https://integrate.api.nvidia.com/v1/models
```

4. Limites -- so UI/docs

Docs NIM nao publicam tabela RPM. UI: "Up to 40 rpm" e texto de interface, nao facto documental. Headers de cota frequentemente ausentes -- "nao declarado". Se 429/exhausted: pivot chat/web em build.nvidia.com. Sem top-up sem Luiz.

5. Pacotes PIX (por valor EMV)

Smoke R\$50 = qr_2 (tag54=50.00). Demo+ R\$100 = qr_3 (tag54=100.00). Nunca qr_0 para R\$20 (EMV de qr_0 = 100). R\$20 = pix-r20.

Landing QR + copia-cola: <https://ziuluiziul.github.io/ane-pagamento/nim/>

Hub: <https://ziuluiziul.github.io/round1-cumulunimbus/>

Gist: <https://gist.github.com/Ziuluiziul/b0991a379c69b1daf94026af7ba8b41f>

6. Nao fazer

- Inventar RPM / cotas / saldo.
- Colar API keys no chat ou no entregavel.
- Cold-DM / spam / fraude.
- Tratar Super 49B 410 como EOL oficial.
- Endossar NVIDIA ou A.N.E. neste pack.

Playbook factual (docs + GET /v1/models + smokes desta conta). Developer Program free. Enterprise US\$4500/GPU/ano = producao, nao meta pessoal.